Анализ данных

Моисеева Александра, 3 курс ФКИ

Проект 1

Проверить на однородность по сумме баллов

а) ГТО и не ГТО, Сочинение и нет, Аттестат и нет.

Отличаются ли люди из общежития и нет.

б) Проверить на независимость баллы по русскому и математике.

Проверка на однородность: ГТО и не ГТО

```
Ttest_indResult(statistic=0.4605149067893822, pvalue=0.6452146962342657)
KstestResult(statistic=0.0739841175973642, pvalue=0.22896205601270903)
```

Предполагаем, что баллы должны быть подчинены нормальному распределению.

Используем критерий Колмогорова-Смирнова и критерий Стьюдента.

Можно сказать, что **однородно**, т.к. p-value>5%.

ГТО не влияет на результат по баллам.

Проверка на однородность: сочинение и нет

```
Anderson_ksampResult(statistic=14.573400508584612, critical_values=array([0.49854918, 1.3236709 , 1.91577682, 2.49304213, 3.24593219,
       3.82285604, 5.12078789]), significance_level=0.001)
```

Используем критерий Андерсона-Дарлинга.

Здесь смотрим на критические значения. Для заданного уровня значимости в 5% - это 1.91578, сравниваем со статистикой 14.5734. Она больше, значит, принимаем альтернативу.

Баллы распределены по-разному, то есть **однородности нет**.

Проверка на однородность: аттестат и нет

```
Ttest_indResult(statistic=-6.498798954988897, pvalue=1.1052877162310367e-10)
KstestResult(statistic=0.15310052097915106, pvalue=1.4664816117004875e-07)
```

p-value очень маленький.

Распределены по-разному.

Проверка на однородность: общежитие и нет

```
Ttest_indResult(statistic=-2.3375387020254177, pvalue=0.019544604995296436)
KstestResult(statistic=0.08144517708840407, pvalue=0.014068655340205294)
```

Неоднородно, т.к. p-value<5%.

Проверка на независимость баллов по русскому и математике

```
Пирсон, линейная зависимость (0.21821316494513918, 2.4514996033261668e-17)
KendalltauResult(correlation=0.11999712149402861, pvalue=1.4490090772664707e-10)
SpearmanrResult(correlation=0.16570794158324373, pvalue=1.5670097922481773e-10)
```

Найдем коэффициенты корреляции Пирсона, Спирмена и Кенделла.

Коэффициенты линейной и монотонной корреляции очень маленькие, значит, корреляции почти нет.

p-value для теста говорит, что нет корреляции, это наша гипотеза. Т.к. у нас p-value маленькое, значит принимаем альтернативу -- корреляция есть, но просто не линейная и не монотонная.

Проект 2

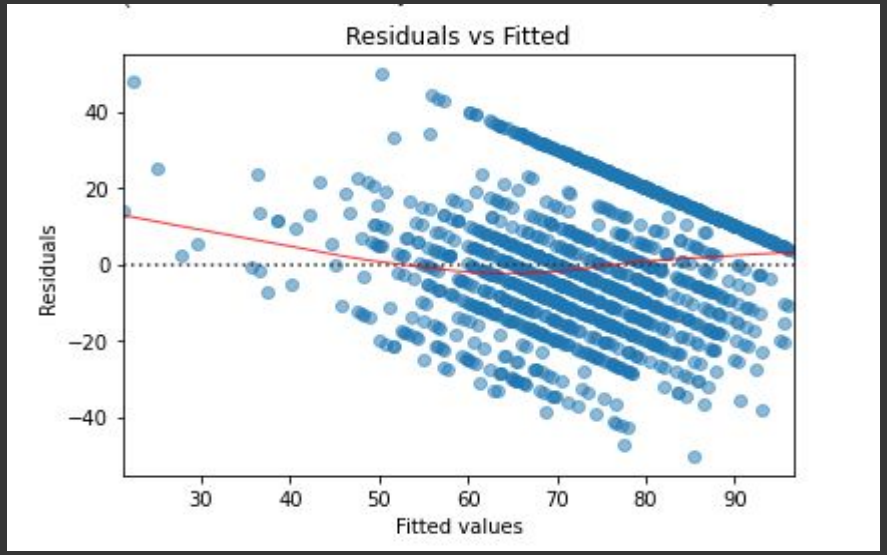
Можем ли предсказать балл по ДВИ на основе остальных баллов? Какое качество регрессионной модели, имеет ли смысл трансформировать предикторы?



Необходимые условия линейной регрессионной модели

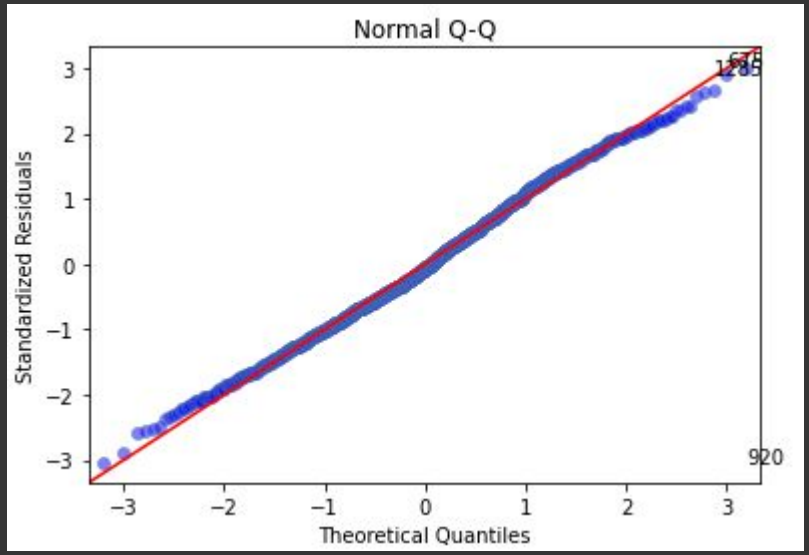
- ➔ Адекватность
- ➔ Гомоскедастичность
- ➔ Некоррелированность ошибок
- ➔ Нормальность

График остатков



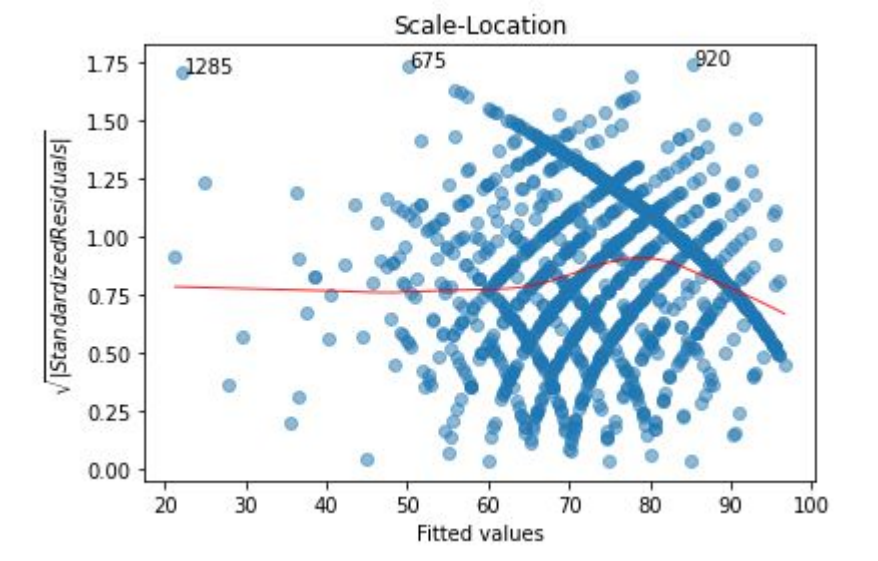
Хороший (почти линейная зависимость), модель адекватна

QQ-plot



Весьма хороший, гипотеза верна, модель адекватна

График Scale-location и критерий Бройша-Пагана




```
het_breuschpagan  (19.96611782636429, 0.0001725090641762502, 6.7297308619938345, 0.00016523624385133824)
```

График Scale-location, позволяющий оценить гомоскедастичность, в принципе хороший, близкий к 0. Но тест, который её проверяет (Критерий Бройша-Пагана), говорит, что она плохая (p-value=0.00016523624385133824). Гипотеза не верна

Критерий Харке-Бера и критерий Дарбина-Уотсона

```
dwtest  (0.03677225934257415, 1.8904995465743804)
```

```
Jarque_beraResult(statistic=12.862320186680227, pvalue=0.0016105813256244161)
```

Некоррелированность ошибок проверяет критерий Дарбина-Уотсона. p-value=3%, это мало, гипотеза не верна.

Критерий Харке-Бера говорит, что ошибки распределены не нормально (pvalue=0.0016105813256244161). Гипотеза не верна



Итого

- **Адекватность - есть**
- **Гомоскедастичность - есть**
- **Некореллированность ошибок - нет**
- **Нормальность - нет**

2 из 4 необходимых условий линейной регрессии выполняется.

Трансформировать предикторы не нужно, видно по линейному графику остатков. Если применить преобразование Бокса-Кокса, будет даже немного хуже

Общая линейная модель для нормальных данных, LinearRegression()

```
Линейная модель:  [-38.09131844   0.97758993   0.44498658  -0.09179164]
```

Удовлетворяет предположению, что ДВИ основывается в первую очередь на балле ЕГЭ за математику.

ДВИ=-38+0.97*м+0.44*ф-0.09*р

Проект 3

Удается ли построить классификатор для того поступил/не поступил (Оригинал)?

Кластеризовать студентов по их баллам иерархической кластеризацией а) стремясь выделить шарообразные кластеры б) стремясь выделить ленточные (вытянутые) кластеры. Какие при этом брать расстояния? Какое число кластеров взять?

– Построение классификатора

Показатель, что классификатор построен==модель обучена.

Классификация бинарная, мы решили использовать линейный дискриминантный анализ. 2/3 выборки сделали тренировочной, остальную часть тестовой. После обучения и проверки на тестовой выборки качество нашей модели(accuracy) составило 84%

```
accuracy  0.8410041841004184
```

Построим объясненную дисперсию:

```
pca=PCA(n_components=8).fit(df)
print(pca.explained_variance_ratio_)
```

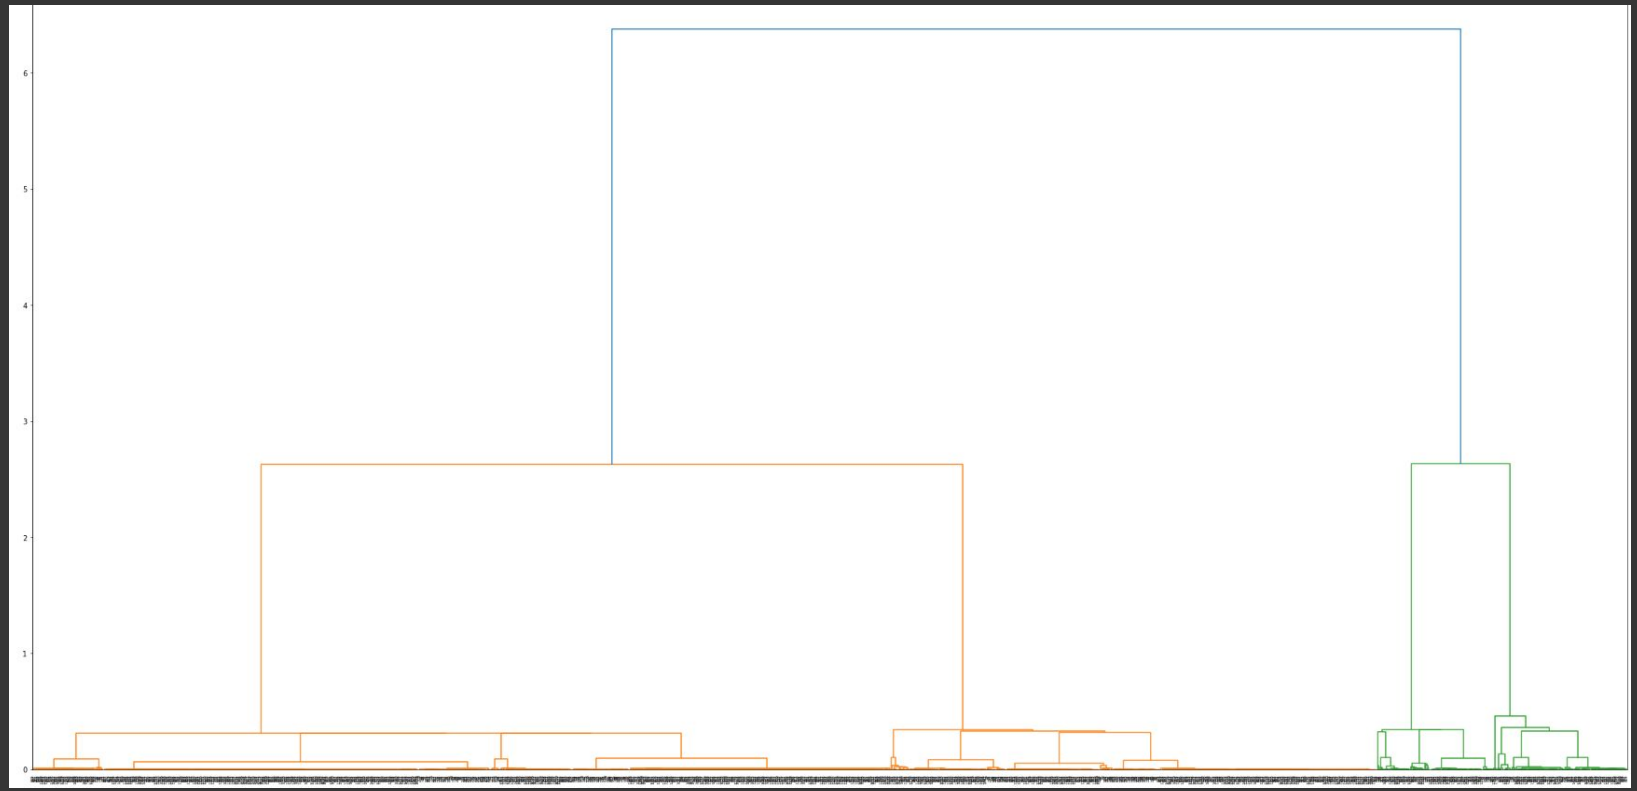
На выходе имеем эти значения:

```
[0.71955839 0.21973875 0.02766453 0.02081024 0.00856487 0.0020623
 0.00085587 0.00074506]
```

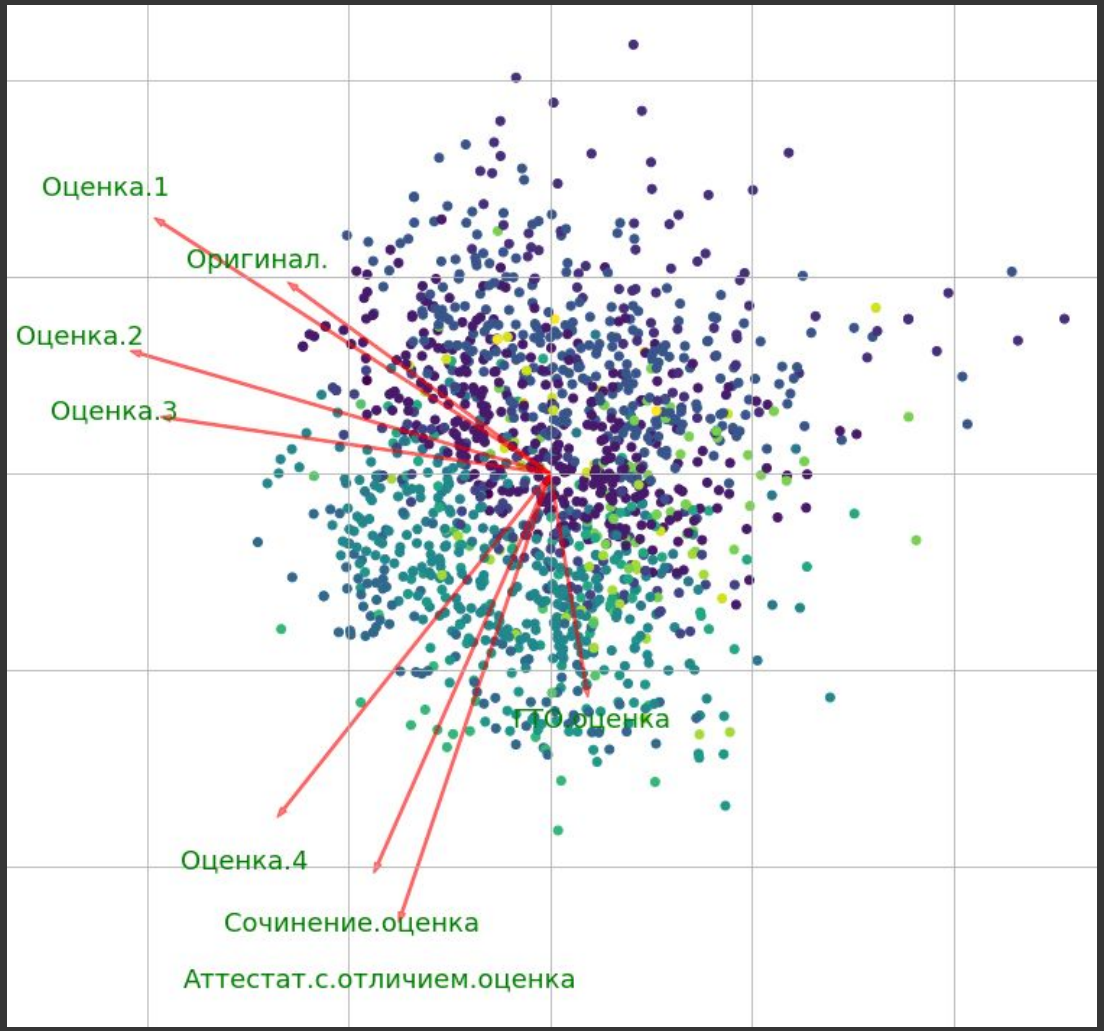
Объясненная дисперсия хорошая, т.к. она не разбросана по всем компонентам. Сумма двух первых компонент более 93%, соответственно через них можно задать остальные векторы. Мы решили попробовать снизить размерность, поэтому построили биплот по двум главным компонентам, у который объясненная дисперсия в сумме даёт 94% Объясненная дисперсия в сумме почти 1 на двух компонентах, значит нам удалось снизить размерность

Для определения количества кластеров и расстояний построим иерархическую дендрограмму:

```
dn=hierarchy.dendrogram(Z)
```



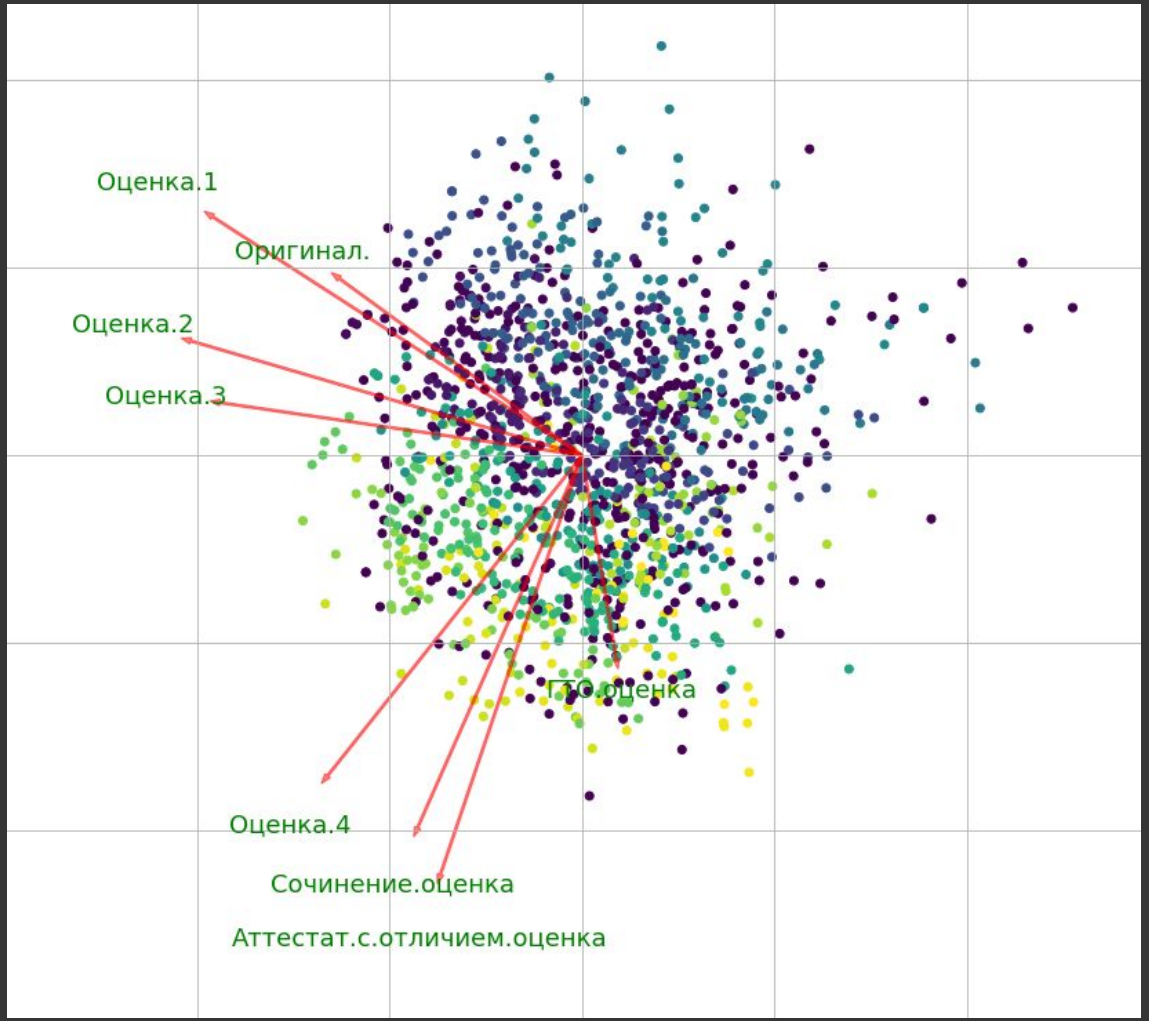
На дендрограмме видно что расстояние примерно 0.3 , а количество кластеров – 4.



DBScan

Для кластеризации студентов по их баллам стремясь выделить ленточные (вытянутые) кластеры воспользуемся методом DBScan:

```
y=DBSCAN(eps=0.3, min_samples=4).fit_predict(D)
```



Optics

Для кластеризации студентов по их баллам стремясь выделить шарообразные кластеры воспользуемся методом Optics:

```
y=OPTICS(min_samples=4).fit_predict(D)
```

Итого

- Классификатор построить удалось.
- Кластеризовать с выделением шарообразных или ленточных классов удалось.
- По итогам дендрограммы взяли 4 кластера с расстояниями 0.3.